

ONCFM

Détection automatique de faux billets

*Organisation Nationale de Lutte
Contre le Faux-Monnayage*

Machine Learning • Python
Kawtar BELKACEMI

Le projet en chiffres

1 500

billets analysés

6

dimensions géométriques

4

algorithmes testés + GridSearchCV

99%

recall sur les faux billets

Le Dataset

1 500

billets au total

dataset complet

dataset complet

1 000

vrais billets

66.7% du dataset

66.7% du dataset

500

faux billets

33.3% du dataset

33.3% du dataset

6 dimensions géométriques mesurées par billet :

diagonal

height_left

height_right


margin_low

margin_up


length

⚠ 37 valeurs manquantes sur margin_low (2.5%) — imputées par Random Forest Regressor

Analyse Exploratoire — Distributions par classe



Boxplots — Vrais vs Faux



Moyennes par classe

length

+0.85

Faux: 111.6mm | Vrai: 113.2mm

margin_low

-0.78


Faux: 5.22mm | Vrai: 4.12mm

diagonal

+0.13

Quasi inutile pour la prédiction

Analyse Exploratoire — Matrice de Corrélation



Corrélations avec is_genuine :

length **+0.85**

margin_low **-0.78**

margin_up **-0.61**


height_right **-0.49**

height_left **-0.38**

diagonal **+0.13**

length & margin_low : variables clés

Imputation des Valeurs Manquantes



Distribution de margin_low — Skewness 0.863

Détection

01

37 NaN sur margin_low
29 vrais / 8 faux — répartition aléatoire
Pas de biais de classe détecté

Méthode choisie

02


Random Forest Regressor
is_genuine exclu du training
→ Aucun data leakage

Résultat


03

Valeurs individualisées
(vs médiane : identique pour tous)
Meilleure représentation statistique

Prétraitement des Données



Train / Validation / Test (64/16/20)



Cross-Validation K-Fold (k=5)

X / y
Split

Train 80%
Test 20%

Stratifi-
cation

Standard-
Scaler

K-Fold
CV k=5

Les Algorithmes Testés

Régression Logistique

Supervisé

Interprétable — probabilités fiables
max_iter=1000, random_state=42

KNN

Supervisé

Classification par proximité
k=5 voisins, distance euclidienne

Random Forest

Supervisé

Ensemble de 100 arbres
Robuste aux outliers


K-Means

Non supervisé

Clustering en 2 groupes
Centroïdes → prédiction de classe


+ GridSearchCV sur la Régression Logistique — 36 combinaisons d'hyperparamètres, scoring sur Recall Faux

Résultats — Matrices de Confusion




Régression Logistique

Recall Faux: 0.98




Random Forest

Recall Faux: 0.98



KNN



Recall Faux: 0.98




K-Means

Recall Faux: 0.98

Comparaison des Modèles



ACP — Structure Naturelle des Données



60%

de variance expliquée
sur 2 composantes

PC1

43.3% — sépare
nettement Vrai/Faux


2

clusters naturels
bien distincts



length & margin_low
portent l'info clé

Validation du Modèle — Cross-Validation



0.982

Recall moyen
par cross-validation

k=5

Folds utilisés
pour la validation

1.000

AUC sur les
courbes ROC

≈ 0%

Écart train/val
→ pas d'overfitting

Modèle Final — Régression Logistique Optimisée


99%

Recall Faux

1 faux billet raté sur 100

95.94% de certitude moyenne

C=0.1 | solver=liblinear



Pourquoi ce modèle :

GridSearchCV : scoring optimisé sur Recall Faux

Interprétable — coefficients explicables

AUC = 1.000 sur les courbes ROC

C=0.1 — sweet spot recall / certitude

Pipeline : StandardScaler + LogisticRegression

Probabilités : ~96% de certitude moyenne

ONCFM

Démonstration Live

Application chargée depuis model_final.pkl — Régression Logistique Optimisée ($C=0.1$)

① Input

Fichier CSV
Dimensions géométriques
du ou des billet(s)

② Prédiction

VRAI billet ✓
ou
FAUX billet ✗

③ Certitude

Probabilité associée
à chaque prédiction
~96% en moyenne

Merci pour votre attention